

7.6 - De Groot

③ Suponha $X_1, \dots, X_n \sim \text{Exp}(\beta)$, com β desconhecido.

Queremos MLE para a mediana que vamos denotar por φ .

Dado que Exp é contínua $P(X_1 \geq \varphi) = 0.5 \Rightarrow e^{-\beta\varphi} = 0.5$, pois

β é o parâmetro da Exp, logo $\log(e^{-\beta\varphi}) = \log(1/2) \Rightarrow -\beta\varphi = -\log 2 \Rightarrow$
 $\Rightarrow \varphi = (\log 2)/\beta$.

Sabemos que o MLE de β é $\hat{\beta} = 1/\bar{X}$. Sendo $g(\beta) = (\log 2)/\beta$.

Pela invariância do estimador $\varphi = g(\beta) \Rightarrow \varphi = g(\hat{\beta}) = \log 2 / \hat{\beta} = 5 \log 2$

Então, $5 \log 2$ é o MLE para φ

5) Sejam $X_1, \dots, X_n \sim \text{Unif}[a, b]$, com a e b desconhecidos, queremos o EMV para $(a+b)/2$.

~~Temos que $f_n(x|a, b) = \prod_{i=1}^n f(x_i|a, b) = \frac{1}{(b-a)^n} \mathbb{I}_{\{a \leq x_i \leq b\}}$~~

~~Se $f_n(x|a, b) > 0$ então $f_n(x_i|a, b) > 0$~~

Sabemos que $\hat{b} = \max(X_i)$ e $\hat{a} = \min(X_i)$ são estimadores MLE para b e a respectivamente, então a média tem MLE

$$\hat{\mu} = \frac{\max(X_i) + \min(X_i)}{2}$$

(11) Suponha que $X_1, \dots, X_n \sim \text{Unif}(0, \theta)$, com θ desconhecido. Mostre que a sequência de MLE de θ é uma sequência consistente.

Temos que mostrar que $\hat{\theta}_n \xrightarrow{P} \theta$.

Sabemos que $\hat{\theta}_n = \max\{X_i\}$ é o MLE de θ , e que $P(X_i \leq \theta) = 1$, assim $P(\hat{\theta}_n \leq \theta) = 1, \forall n \in \mathbb{N}$

$$\begin{aligned} P(\theta - \hat{\theta}_n < \varepsilon) &= P(\hat{\theta}_n > \theta - \varepsilon) \\ &= 1 - P(\hat{\theta}_n \leq \theta - \varepsilon) \\ &= 1 - P(X_1 \leq \theta - \varepsilon, \dots, X_n \leq \theta - \varepsilon) \\ &= 1 - P(X_1 \leq \theta - \varepsilon) \cdots P(X_n \leq \theta - \varepsilon) \\ &= 1 - P(X_1 \leq \theta - \varepsilon)^n \\ &= 1 - \left(\frac{\theta - \varepsilon}{\theta}\right)^n \rightarrow 1, \text{ quando } n \rightarrow \infty \end{aligned}$$

, pois $\theta - \varepsilon < \theta$

concluimos que $\hat{\theta}_n \xrightarrow{P} \theta$.

20) Queremos provar que o ^{estimador} método dos momentos da média da Poisson é o MLE.

Seja $X_1, \dots, X_n \sim \text{Poisson}(\theta)$

MLE:

$$f_n(x|\theta) = \frac{e^{-n\theta} \theta^{\sum x_i}}{\prod x_i!}$$

$$\Rightarrow L(\theta|x) = -n\theta + \sum x_i \ln \theta + \sum \ln(x_i!)$$

$$\text{Assim, } \frac{\partial}{\partial \theta} L(\theta|x) = -n + \frac{\sum x_i}{\theta} = 0 \Rightarrow \hat{\theta} = \bar{X}_n$$

Momentos:

Temos 1 momento θ . Além disso $E(X_i) = \theta$ é finito. Podemos usar o método. O método momental é $m_1 = \frac{1}{n} \sum x_i$ e $\mu_1(\theta) = E(X_i|\theta) = \theta$. Logo pelo método dos momentos $\bar{X}_n = m_1 = \mu_1(\hat{\theta}) = \hat{\theta}$

22) Seja $X_1, \dots, X_n \sim \text{Unif}[0, \theta]$

a) Queremos encontrar o EMM de θ .

Tomar que θ é 1-dimensional e $E[X|\theta] = \theta/2$ é finita, logo o método amostral é $m_i = \frac{1}{n} \sum X_i$ e $\mu_i(\theta) = E(X_i|\theta) = \theta/2$. Então o EMM é $\bar{X}_n = \frac{\hat{\theta}}{2} \Rightarrow \hat{\theta} = 2\bar{X}_n$.

b) Note que, $2\bar{X}_n \neq \max(X_1, \dots, X_n) = \hat{\theta}_{MLE}$

(23) Seja $X_1, \dots, X_n \sim \text{Beta}(\alpha, \beta)$ e seja $\theta = (\alpha, \beta)$.

a) Queremos encontrar o EMM para θ , só que aqui temos 2 parâmetros. Como média e variância estão definidas.

$$m_1 = \frac{1}{n} \sum x_i = \bar{X}_n \text{ e } m_2 = \frac{1}{n} \sum x_i^2. \text{ Além disso, } \mu_1(\theta) = E(X_1|\theta) = \frac{\alpha}{\alpha+\beta}$$

$$\mu_2 = E(X_1^2|\theta) = \text{Var}(X_1|\theta) + E(X_1|\theta)^2$$

$$= \frac{\alpha\beta}{(\alpha+\beta)(\alpha+\beta+1)} + \frac{\alpha^2}{(\alpha+\beta)^2}$$

$$= \frac{\alpha}{(\alpha+\beta)^2} \left[\frac{\beta}{(\alpha+\beta+1)} + \alpha \right]$$

$$\text{Pelo método } \bar{X}_n = \frac{\hat{\alpha}}{\hat{\alpha} + \hat{\beta}} \text{ e } \frac{1}{n} \sum x_i^2 = \frac{\hat{\alpha}}{(\hat{\alpha} + \hat{\beta})^2} \left[\frac{(\hat{\alpha} + \hat{\beta})(\hat{\alpha} + 1)}{(\hat{\alpha} + \hat{\beta} + 1)} \right]$$

$$\hat{\alpha}(1 - \bar{X}_n) = \hat{\beta} \bar{X}_n \Rightarrow \hat{\alpha} = \frac{\hat{\beta} \bar{X}_n}{(1 - \bar{X}_n)}$$

$$\text{Logo, } \frac{1}{\bar{X}_n} = \frac{1}{n} \sum x_i^2 = \frac{\hat{\beta} \bar{X}_n / (1 - \bar{X}_n) + 1}{\hat{\beta} \bar{X}_n / (1 - \bar{X}_n) + \hat{\beta} + 1} = \frac{\hat{\beta} \bar{X}_n + 1 - \bar{X}_n}{\hat{\beta} + 1 - \bar{X}_n}$$

$$\Rightarrow (\hat{\beta} + 1 - \bar{X}_n) \sum x_i^2 = n \bar{X}_n (\hat{\beta} \bar{X}_n + 1 - \bar{X}_n)$$

$$\Rightarrow \hat{\beta} [\sum x_i^2 - n \bar{X}_n \bar{X}_n] = n \bar{X}_n (\hat{\beta} \bar{X}_n + 1 - \bar{X}_n) - n \bar{X}_n^2 + \bar{X}_n \sum x_i^2 - \sum x_i^2$$

$$\Rightarrow \hat{\beta} = \frac{[\bar{X}_n - \bar{X}_n^2] \sum x_i^2 + \bar{X}_n \bar{X}_n^2 - \bar{X}_n^2}{\bar{X}_n^2 - \bar{X}_n^2} = \frac{(1 - \bar{X}_n)(\bar{X}_n - \bar{X}_n^2)}{\bar{X}_n^2 - \bar{X}_n^2}$$

$$\text{Por fim } \hat{\alpha} = \frac{(\bar{X}_n - \bar{X}_n^2)}{\bar{X}_n^2 - \bar{X}_n^2} \cdot \bar{X}_n$$

$$b) f(x|\theta) = \frac{(\pi x)^{\alpha-1} (\pi(1-x))^{\beta-1}}{B(\alpha, \beta)^n}$$

$$L(\theta|x) = (\alpha-1) \sum \ln(x_i) + (\beta-1) \sum \ln(1-x_i) - n[\ln(\Gamma(\alpha)) + \ln(\Gamma(\beta)) - \ln(\Gamma(\alpha+\beta))]$$

$$\frac{\partial L}{\partial \alpha} = \sum \ln(x_i) - n \frac{\Gamma'(\alpha)}{\Gamma(\alpha)} + \frac{\Gamma'(\alpha+\beta)}{\Gamma(\alpha+\beta)} = 0$$

tilibra Note que, o valor envolve $\sum \ln(x_i)$ que não aparece no EMM, logo não é o mesmo.